



Instituto Tecnológico
de Buenos Aires

Trabajo Práctico N° 1

Segundo cuatrimestre de 2026

Integrantes:

María Sol Allievi	65774
Martina Risso	65688
Dante Tosoratti	65823
Tomás Agustín Picciolo	63690

Fecha de entrega: 9 de Septiembre de 2026

1. Definición del negocio y alcance operativo

1.1 Contexto e interlocutor

El mercado inmobiliario de CABA presenta una fuerte dispersión de información: a partir de un aviso individual no es sencillo determinar si el precio pedido está alineado con propiedades comparables o si existe una oportunidad real de compra. Nuestro equipo se posiciona como una consultora PropTech que trabaja para un Fondo de Inversión Inmobiliario interesado en detectar propiedades subvaluadas y, dentro de ese universo, identificar casos con potencial de refacción y reventa (flipping).

El problema se aborda como un problema de valuación relativa. Primero se busca estimar cuánto debería valer una propiedad de acuerdo con comparables de características similares. Luego se compara ese valor esperado con el precio publicado. La diferencia constituye la señal de subvaluación y, para los inmuebles que requieren obra, sirve como punto de partida para evaluar si el descuento compensa el costo de refacción y los demás costos de la operación.

1.2 Alcance operativo

Para mantener comparabilidad entre observaciones, se define el siguiente universo de análisis:

- **Ubicación:** CABA, todos los barrios.
- **Operación:** venta.
- **Tipología principal:** departamentos.
- **Condición:** stock usado. Se excluyen publicaciones en pozo, preventa, en construcción y a estrenar cuando la evidencia del aviso permite identificarlas.
- **Moneda principal de análisis:** USD.
- **Unidad de observación:** aviso individual de una propiedad.
- **Momento inicial:** primera corrida completa del scraper. Para estudiar permanencia en mercado se realizarán capturas sucesivas.

La extracción cruda conserva otras tipologías porque forman parte de la respuesta original de la fuente. El filtro a departamentos usados se aplica en la etapa de curaduría, de modo que la base raw permanezca reproducible y completa.

1.3 Encuadre estratégico

Subvaluación y flipping no se tratan como dos problemas independientes. Una operación de flipping sólo resulta atractiva si el inmueble se compra con suficiente descuento respecto de su valor esperado posterior a la refacción. Por eso, el núcleo del proyecto es construir una referencia de valor comparable y, a partir de ella, ordenar oportunidades de inversión.

2. Preguntas de investigación

Nivel descriptivo

1. ¿Cuál es el precio promedio, mediano y la dispersión del USD/m² por barrio y cómo varía según superficie, ambientes y antigüedad?

2. ¿Qué diferencia de USD/m2 existe entre departamentos que necesitan obra y departamentos reciclados/refaccionados comparables?
3. ¿Qué proporción de la oferta usada puede clasificarse como “necesita obra”, “buen estado”, “reciclada/refaccionada” o permanece sin evidencia suficiente para clasificar?
4. ¿Qué características y amenities aparecen con mayor frecuencia en cada segmento de precio?
5. ¿Cuánto tiempo permanece observado un aviso antes de dejar de aparecer en las capturas sucesivas?

Nivel diagnóstico

1. ¿Qué variables disponibles explican mejor las diferencias de precio entre propiedades comparables de una misma zona?
2. ¿El descuento asociado a “necesita obra” es similar en todos los barrios o cambia según la zona?
3. ¿Qué relación presentan amenities como cochera, balcón, seguridad, pileta o terraza con el USD/m2 dentro de segmentos comparables?
4. ¿La dispersión del USD/m2 dentro de un barrio permite identificar micro-mercados u oportunidades que un promedio general oculta?

Etapas posteriores del análisis: a partir de los patrones identificados en las etapas descriptiva y diagnóstica, se evaluará la posibilidad de estimar un valor de referencia para cada propiedad según sus características y, posteriormente, utilizar esa estimación para identificar y priorizar oportunidades de inversión y flipping.

3. KPIs y definiciones operativas

KPI	Definición matemática	Interpretación comercial
USD/m2 observado	$\text{Precio_Valor} / \text{Superficie_Total_m2}$	Permite comparar propiedades de distinto tamaño en una misma unidad de valor.
Benchmark USD/m2 comparable	Mediana del USD/m2 de propiedades comparables por zona, ambientes y banda de superficie	Referencia robusta de mercado para el segmento de la propiedad.
Precio esperado	$\text{Benchmark_USD_m2} * \text{Superficie_Total_m2}$	Valor de referencia aproximado para una propiedad con características comparables.
Gap de subvaluación	$(\text{Precio_Esperado} - \text{Precio_Publicado}) / \text{Precio_Esperado} * 100$	Señal porcentual de cuánto más barata está publicada una propiedad respecto de su benchmark.
Gap de estado / flipping	$(\text{Mediana_USD_m2_Reciclada} - \text{Mediana_USD_m2_Necesita_Obra}) / \text{Mediana_USD_m2_Reciclada} * 100$	Mide el descuento observado asociado a la necesidad de refacción dentro de segmentos comparables.

KPI	Definición matemática	Interpretación comercial
Costo estimado de refacción	$\text{Superficie_Cubierta_m2} * \text{Costo_Refaccion_USD_m2}$	Aproxima la inversión necesaria para llevar una propiedad a un estado comparable post-obra.
Inversión total estimada	$\text{Precio_Compra} + \text{Costo_Refaccion} + \text{Costos_Transaccion}$	Capital total comprometido en la operación.
Margen potencial de flipping	$\text{Precio_Esperado_PostObra} - \text{Inversion_Total}$	Ganancia potencial en USD antes de impuestos y costos no modelados.
ROI potencial de flipping	$\text{Margen_Potencial} / \text{Inversion_Total} * 100$	Permite comparar oportunidades de distinto tamaño de inversión.

Umbral inicial de subvaluación. Se propone utilizar 15% como umbral operativo preliminar para construir un primer ranking de oportunidades. No se lo presenta como un valor definitivo: será recalibrado en la segunda pre-entrega a partir de percentiles, dispersión de los gaps y costos de operación documentados.

Costo de refacción. El índice de costo de construcción del INDEC se utilizará como insumo de actualización/normalización, pero no se asumirá que equivale directamente a un costo de refacción por m2. Será necesario definir una referencia base de costo de obra y llevarla a una unidad monetaria comparable con los precios de venta.

4. Hipótesis iniciales y hoja de ruta

4.1 Hipótesis a validar

H1. Descuento por condición. Los departamentos que necesitan obra presentan un USD/m2 menor que los reciclados/refaccionados, incluso al comparar propiedades de la misma zona y con características similares.

H2. Heterogeneidad espacial. La dispersión del USD/m2 no es igual en todos los barrios, las zonas con mayor dispersión pueden contener más oportunidades de subvaluación relativa.

H3. Existencia de oportunidades de flipping. En una parte de los casos que necesitan obra, el descuento de entrada supera el costo estimado de refacción y los costos de la operación, generando un margen potencial positivo.

4.2 Hoja de ruta analítica

- **Pre-Entrega 1:** definición del negocio, alcance, preguntas, KPIs, hipótesis, arquitectura de datos y extracción raw.
- **Pre-Entrega 2:** limpieza formal, auditoría de calidad, tratamiento de faltantes/outliers, feature engineering sobre texto y amenities, cálculo de KPIs y EDA.
- **Pre-Entrega 3:** integración espacial y económica, validación formal de hipótesis, reducción de dimensionalidad, clustering de micro-mercados y, si corresponde, modelos explicativos.

- **Entrega final:** dashboard en Power BI/Tableau, ranking de oportunidades y presentación ejecutiva orientada al fondo de inversión.

5. Ejecución técnica de la extracción

5.1 Fuente y estrategia de extracción

En lugar de utilizar el script base de Argenprop provisto por la cátedra, se desarrolló un extractor propio sobre la API interna que alimenta el sitio de RE/MAX. La consulta se restringió a Capital Federal y operación de venta.

Se priorizó la API frente al parseo directo del HTML porque devuelve información estructurada en JSON y permite manejar la paginación de forma más estable. La arquitectura de extracción quedó planteada de la siguiente manera:

Endpoint de listado paginado -> IDs/slugs de propiedades -> endpoint de detalle -> JSON -> normalización en Pandas -> dataframe maestro raw -> snapshots sucesivos.

5.2 Variables capturadas

El endpoint de listado permite obtener precio, moneda, expensas, tipología, ambientes, dormitorios, baños, superficies, dirección, barrio/ubicación, coordenadas y estado de la publicación. El endpoint de detalle agrega descripción completa, antigüedad y apto crédito.

Grupo	Variables principales
Identificación	ID, ID_Entidad, ID_Interno, Link
Comerciales	Operacion, Precio_Valor, Moneda, Expensas, Moneda_Expensas, Precio_m2_Total, Precio_m2_Cubierto
Físicas	Tipo_Propiedad, Ambientes, Dormitorios, Baños, Superficie_Total_m2, Superficie_Cubierta_m2, Antigüedad
Ubicación	Direccion, Barrio, Ubicacion, Latitud, Longitud
Texto libre	Título, Descripción
Otras	Fecha_Publicacion, Apto_Credito, Amenities, Estado

5.3 Tipos de datos

La extracción combina distintos tipos de información necesarios para el análisis:

- **Textuales:** Título, Descripción, Dirección.
- **Numéricas continuas:** Precio_Valor, Expensas, superficies, precios por m2, Latitud, Longitud, Antigüedad.
- **Numéricas discretas:** Ambientes, Dormitorios, Baños.
- **Catógoricas nominales:** Tipo_Propiedad, Barrio, Moneda y Estado de publicación.
- **Dicotómica:** Apto_Credito.
- **Ordinal derivada - avance de la etapa siguiente:** Estado_Propiedad, construida exploratoriamente a partir del texto. En la base raw no se fuerza como ordinal una variable que conceptualmente no lo sea.

5.4 Desafíos técnicos y soluciones implementadas

Desafío	Solución
El listado no incluía descripción, antigüedad ni apto crédito	Se realizó una consulta adicional a la ficha individual de cada propiedad para obtener los campos que no estaban disponibles en el listado general.
El primer endpoint de detalle por ID devolvía errores internos	Se revisó cómo el sitio cargaba la información y se identificó la ruta correcta para acceder al detalle de cada propiedad.
El filtro de Capital Federal depende de un parámetro frágil	Se agregó una validación inicial para detectar respuestas vacías o cambios inesperados en la fuente de datos.
La consulta secuencial de miles de detalles era demasiado lenta	Se realizaron las consultas en paralelo para reducir el tiempo de ejecución, incorporando además reintentos y registro de errores.
El campo Fecha_Publicacion no llega informado	Se diseñó seguimiento propio por corridas mediante fechas de primera y última captura para medir permanencia observada.

5.5 Evidencia de la primera corrida raw

La primera corrida completa generó un dataframe maestro de **16.993 filas y 29 columnas**, recorriendo **171 páginas**. El campo de ubicación devuelve **75 etiquetas distintas** en el universo crudo; estas etiquetas no se asumirán como barrios oficiales y más adelante, estas ubicaciones se ajustarán utilizando los límites oficiales de los barrios. Como control inicial de captura se observó:

- Fecha_Publicacion: 100% faltante.
- Amenities: 23,72% faltante.
- Expensas: 7,15% faltante.
- Antigüedad: 3,38% faltante.
- Precio_m2_Cubierto: 3,04% faltante.
- Descripción y Apto_Credito: 0,62% faltante cada una.
- El resto de los faltantes relevantes se encuentra por debajo del 0,1%.

Estos controles se documentan en esta etapa como evidencia de calidad de captura. El tratamiento de faltantes y la decisión de imputar, excluir o conservar consideramos que corresponde formalmente a la Pre-Entrega 2.

6. Avance exploratorio de limpieza

El equipo se adelantó parcialmente a la segunda etapa y realizó una primera limpieza exploratoria. Este trabajo se incluye como **avance**, sin reemplazar el foco de la Pre-Entrega 1 sobre la base raw.

A partir de los 16.993 registros originales se construyó una base de **9.671 departamentos usados y 44 variables**, luego de excluir tipologías fuera del alcance, publicaciones nuevas/en desarrollo, duplicados reales y algunos casos no comparables con una compraventa residencial convencional. El criterio fue conservador: no eliminar outliers únicamente por ser extremos, sino revisar si existía una razón concreta para considerarlos errores o casos fuera del universo analítico.

También se generaron variables binarias de amenities y una variable exploratoria Estado_Propiedad a partir de Titulo y Descripcion. La clasificación preliminar resultó en:

Estado_Propiedad	Registros
Sin_clasificar	6.170

Buen_estado	2.000
Reciclada_refaccionada	1.085
Necesita_obra	416

La existencia de una gran cantidad de casos sin clasificar refuerza la necesidad de mantener criterios conservadores y de no inferir el estado del inmueble cuando el aviso no aporta evidencia suficiente. Estos resultados deberán formalizarse y validarse en la segunda pre-entrega.

7. Plan de integración de fuentes externas

Para las próximas etapas del proyecto se prevé incorporar distintas fuentes externas que permitan enriquecer la información obtenida mediante el scraping y explicar mejor las diferencias de precio entre propiedades.

Polígonos oficiales de barrios — BA Data

<https://data.buenosaires.gob.ar/dataset/barrios>

Se utilizarán para validar y asignar correctamente el barrio de cada propiedad a partir de sus coordenadas de latitud y longitud. Esto permitirá trabajar con una división geográfica uniforme y evitar depender únicamente de la ubicación informada en cada publicación.

Estaciones de Subte — BA Data

<https://data.buenosaires.gob.ar/dataset/subte-estaciones/resource/juqdkmgo-1994-resource>

Se utilizarán para calcular la distancia entre cada propiedad y la estación de subte más cercana, con el objetivo de analizar si la cercanía al transporte público está asociada con diferencias en el precio por m².

Estaciones de Ferrocarril — BA Data

<https://data.buenosaires.gob.ar/dataset/estaciones-ferrocarril>

Al igual que con las estaciones de subte, se calculará la distancia a la estación de tren más cercana para incorporar otra medida de accesibilidad y conectividad de cada propiedad.

Espacios Verdes — BA Data

<https://data.buenosaires.gob.ar/dataset/espacios-verdes>

Se utilizarán para calcular la distancia de cada propiedad al espacio verde más cercano y analizar si la proximidad a plazas o parques tiene relación con el valor de las propiedades.

Índice del Costo de la Construcción — INDEC

<https://www.indec.gob.ar/indec/web/Nivel4-Tema-3-5-33>

Se utilizará como referencia para estimar y actualizar el costo de refacción. Como este índice se encuentra expresado en pesos y los precios de las propiedades se analizan principalmente en dólares, será necesario convertir los valores a una misma moneda.

Establecimientos educativos — BA Data

<https://data.buenosaires.gob.ar/dataset/establecimientos-educativos>

Se utilizarán para calcular la distancia entre cada propiedad y los establecimientos educativos más cercanos, diferenciando según el tipo de institución cuando sea posible. Esto permitirá analizar si la proximidad a escuelas, colegios y otras instituciones educativas está asociada con diferencias en el precio por m² de las propiedades.

Hospitales — BA Data

<https://data.buenosaires.gob.ar/dataset/hospitales>

Se utilizarán para calcular la distancia entre cada propiedad y el hospital más cercano, incorporando la disponibilidad y accesibilidad a servicios de salud como una característica del entorno. Esto permitirá analizar si la cercanía a hospitales está relacionada con diferencias en el precio por m² de las propiedades.

Tipo de cambio histórico — fuente a definir

Este dataset se cruzará con la información del Índice del Costo de la Construcción para convertir los costos expresados en pesos a dólares de forma consistente. La fuente definitiva de tipo de cambio se definirá al momento de realizar esta integración.

